

HW2

R14H41007 統計碩士學位學程一石欽鈺

March 22, 2026

(因有些中文無法透過 latex 顯示，所以中間會穿插英文，不好意思)

Q2. Perform logistic regression and Fisher LDA to the ILPD (Indian Liver Patient Dataset) and make proper comparisons.

Introduction. data : ILPD (印度肝病數據集) ; 二元分類; input features : age, gender, and 8 others index; target : 判斷該患者是否患有肝病 (1 是, 2 否) ; tool: Logistic Regression(without assuming data are from gaussian dist.)/ Fisher's LDA(Did assume data are from gaussian dist.); evaluate: accuracy(error rate), sensitivity, and specificity.

Discussion. The following table shows the comparison in performance between 2 methods.

Table 1: Comparison Table

Metrics	Logistic Regression		Fisher LDA	
<i>Overall</i>				
Error Rate	0.2393		0.2735	
AUC	0.8130		0.7517	
Accuracy	0.76		0.73	
分項指標	Healthy	Patient	Healthy	Patient
Precision	0.56	0.79	0.33	0.75
Recall	0.30	0.92	0.07	0.95
F1-Score	0.39	0.85	0.11	0.84
Support	30	87	30	87

Overall, Logistic Regression 與 LDA 在皆展現了基礎的 identified-ability, 其中 Logistic Regression 以 AUC 0.8130 與錯誤率 0.2393 的表現優於 LDA 的 0.7517 與 0.2735, 可推得資料應該不是 gaussian distribution, 所以 Logistic 有比較好的表現。不過, 分項指標告訴我們細節上這兩個方法適不適用於這筆數據。這兩套基於 linear 邊界的方法都展現了高度“保守”的臨床診斷特性, 兩者對 Patient 的 Recall all up to 0.92, 代表模型極力避免漏掉任何患者, 但模型寧可錯殺也不可放過, 會導致 a pretty low identified-ability in "Healthy"。

Especially, "Healthy Recall" in LDA only 0.07, 以題目的 sample size 來講, 30 名健康受試者中中有 2 名被正確 indentify, 誤診的機率極高, 在實務使用上好像不大優。Logistic Regression 的 Healthy Recall 也只有 0.30, 但已好於 LDA。The recalls in

healthy and patient are quite different, 主因於 ILPD 中病患樣本數三倍多於健康樣本，加上生化指標通常不符合 LDA 嚴格的 gaussian distribution 與共用 variance matrix 假設，導致 LDA 的 decision boundary 邊界發生嚴重偏移，將大多數觀測值歸類成病患。綜上所述，雖然 Logistic Regression 的整體 accuracy 較高，但兩模型在面對 atogories unbalanced 數據時，皆需配合門檻值調整或樣本平衡技術，方能改善對”healthy” 極低捕捉力的問題。

再來討論 Precision and F1-score，Logistic Regression stii got better score in ”healthy”。代表在臨床實務中，當 LDA 告訴一名受試者『你是健康的』時，可信度低，可能低於隨機猜測；相較之下，Logistic Regression 的診斷結果較具參考價值。最後，從 F1-Score 觀察模型的平衡性，Logistic Regression 在兩類獲得 0.39 / 0.85，healthy 仍不盡人意但比 LDA 平衡些，可謂是比較有 identified-ability 的方法。而 LDA 的 0.11，顯示在 catogories unbalanced (30 vs 87) 且數據不符合 gaussian distribution 時，LDA 的 decision boundary 嚴重偏移，幾乎喪失了對”healthy” 的區分能力。

In conclusion, Logistic Regression 更適用於這份 data，不過他仍無法應對對於樣本數不足，更不用談 LDA 在這種不符合 gaussian distribution 假設的 data 多難適應，所以我認為這份 data 需要其他更適配的分類方法。

Q3. 實作平滑樣條，利用一種特殊的交叉驗證法來尋找最合適的平滑參數 λ 。

Introduction. 平滑樣條公式：

$$RSS(f, \lambda) = \sum_{i=1}^N \{y_i - f(x_i)\}^2 + \lambda \int \{f''(t)\}^2 dt$$

第一項（數據擬合）：希望 curve 離點越近越好；第二項（粗糙度懲罰）： $f''(t)$ 代表曲線的彎曲程度。如果這項很大，代表曲線抖動得很厲害。當 $\lambda \rightarrow 0$ ：完全不懲罰抖動，曲線會穿過每個點（插值），variance 極大；當 $\lambda \rightarrow \infty$ ：極度討厭彎曲，最後會逼成一條 line。

Use Leave-one-subject-out Cross-Validation to choose λ 。在骨密度（BMD）這個數據集中，同一個青少年可能有多筆測量。每次剔除「某一個受試者」（一般的 CV 是隨機刪除資料點，但這裡必須整個人刪除）的所有資料，用剩下的受試者訓練模型，再回來預測被剔除的那個人。確保模型學到的是「人類成長的普遍規律」，而不是死背某幾個特定人的數據。

Discussion. Is $\lambda = 0.00022$ a good choice? Yes!! 從下圖與下表可知，無論是男性或女性，都是對應到 $\lambda = 0.00022$ 對應到的自由度 12。在上圖（模擬圖形）中，此設定能清晰捕捉女性（12 歲）與男性（14 歲）的發育 peak，無論是高峰還是低谷，該有的轉折皆沒有忽略，即便在某些區間兩種類別的測量結果有點重疊，個體間的隨機雜訊也被有效過濾。因此， $\lambda = 0.00022$ 是一個在生物學解釋性與預測穩健性之間取得優異平衡的選擇。

Table 2: Smoothing Splines 擬合參數

Sex	最佳平滑參數 (s)	df	Mean MSE
男性 (Male)	0.138950	≈ 11.2	0.00154
女性 (Female)	0.051795	≈ 12.8	0.00128

註：課本建議之 $\lambda = 0.00022$ 約對應 12 個自由度。




Table 3: Relative Change in BMD in Distinct Ethnicity

族群 (Ethnicity)	平均發育強度 ($\bar{y}$)	Std)
非裔 (Black)	0.039118	0.0412
白裔 (White)	0.035954	0.0385
差異 (Diff)	+0.003164	—

Is there any difference between ethnicities? Yes!! 族群之間存在差異，不墮差距並不是太大。下表的”Diff” 欄位顯示，不同族群在發育強度上存在位移：

$$\bar{y}_{Black} \approx 0.0391 > \bar{y}_{White} \approx 0.0359$$

，非裔受試者的骨密度相對變化量平均高於白裔。這說明在建立青少年發育模型時，族群是一個不可忽視的解釋變數，若忽略族群差異，將導致模型對特定群體的預測產生偏差。